

客户端发送请求



openAI 兼容 API 接收请求



Tokenizer: 把文字变为Token编号



Scheduler



Radix Cache



预) KV cache 可以缓存

没有缓存



prefill: 计算尚未缓存的



Decode



把新产生的 KV cache 存储



token 转回文字



API 返回客户端