

重点回答：

1.SGLang 的 RadixAttention / RadixCache 解决什么问题？

在有多条请求时，如果有相同的 prompt 前缀，模型可以不用重复计算这段重复内容。RadixTree 负责保存前缀以及他们的 kV cache。RadixCache 可以查找保存的相同前缀，复用已经计算好的 kV cache，只对没有缓存的部分进行计算，降低 TTFT。

2.SGLang 中 page-sized KV cache 与 prefix reuse 分别对应 pipeline 中的哪一部分？

page-sized KV cache：把 kVcache 切分成固定大小的 block，并分散存储在 GPU 显存中，在 decode 之后。

prefix reuse：prefill 之前找到可以复用的前缀 token，在 decode 之前。

3.vLLM 的 PagedAttention 解决什么问题？它和 SGLang 的 RadixAttention / paged KV 机制有什么联系与差异

vLLM 的 PagedAttention 把 kV cache 切分成固定大小的 block，并分散储存。这样使得 kVcache 不用连续存储占用大量内存，可以按需分配回收。

RadixAttention / paged KV 重点在于复用这些缓存，而 vLLM 的 PagedAttention 则是重点在于如何存储这些缓存。